roary_split.py 的目标是根据数量超过特定阈值的每个物种,分别创建文件夹。在每个文件夹 内,生成一个 txt 文件,记录该物种的所有 MAGs,并在物种文件夹下创建指向 Prokka 注释 的 gff 文件的软链接。输入文件包括 species.txt 和 tax.bac120.summary.tsv 两个文件。

其中, species.txt 记录了每个组装的 MAG 的数量:

```
Sacteria;p, Actinomyceota;c, Coriobacteria;c) Goriobacteriales;f Goriobacteriaceae;g Collinsella;s, Collinsella sp803436275
Sacteria;p, Bacillota A;c Clostridia;c) Clostridiales;f Coriobacteriaceae;g Clostridium_J:c. Clostridium_Oubtroemicium
Sacteria;p, Bacillota A;c Clostridia;c) Clostridiales;f Clostridiaceae;g Clostridium_J:s. Clostridium_Oubtroemicium
Sacteria;p, Bacillota A;c Clostridia;c) Clostridiales;f Clostridiaceae;g Clostridium_S:c. Clostridium_S
Sacteria;p, Bacillota A;c Clostridia;c) Lahonspirales;f Lachonspiraceae;g_Enteroclosters_Enteroclosters_sp80120905
Sacteria;p, Bacillota A;c Clostridia;c) Lahonspirales;f Lachonspiraceae;g_Enteroclosters_Enteroclosters_sp80120905
Sacteria;p, Bacillota;c, Bacilli;o, Bacillales;f Sacillaceae,g;g_Bacillus;s_Bacillus applicated;c, Bacilli;o, Bacillales;f Sacillaceae,g;g_Bacillus;a,g; Bacillus A bombysepticus
Sacteria;p, Bacillota;c, Bacilli;o, Bacillales;f Sacillaceae,g;g_Bacillus;a,g; Peristria;p, Sacillaceae,g;g_Bacillus;a,g; Peristria;p, Prestria;p, Sacillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Facillaceae,g;g_Fac
```

tax.bac120.summary.tsv,其记载了每个 MAG 所属的 species:

```
seudomonadota;c__Gammapro
acillota;c__Bacilli;o__La
seudomonadota;c__Gammapro
acillota;c__Bacilli;o__La
```

使用方法:

python roary_split.py -help

- -i: 输入文件 1, species.txt 文件
- --tax: 输入文件 2, tax.bac120.summary.tsv 文件
- -t: genome 数量的阈值,只有超过该数值的 genome 才会被创建文件夹,默认: 10
- -p: Prokka 文件夹。注意必须为绝对路径,不能使用相对路径
- -o: 输出文件,输出每个种及其对应的 species 数目用于后期作图。