roary_split.py 的目标是根据数量超过特定阈值的每个物种,分别创建文件夹。在每个文件夹 内,生成一个txt 文件,记录该物种的所有 MAGs,并在物种文件夹下创建指向 Prokka 注释 的 gff 文件的软链接。输入文件包括 species.txt 和 tax.bac120.summary.tsv 两个文件。

其中, species.txt 记录了每个组装的 MAG 的数量:

```
Sacteria;p, Actinomyceota;c, Coriobacteria;c) Goriobacteriales;f Goriobacteriaceae;g Collinsella;s, Collinsella sp803436275
Sacteria;p, Bacillota A;c Clostridia;c) Clostridiales;f Coriobacteriaceae;g Clostridium_J:c. Clostridium_Oubtroemicium
Sacteria;p, Bacillota A;c Clostridia;c) Clostridiales;f Clostridiaceae;g Clostridium_J:s. Clostridium_Divricum
Sacteria;p, Bacillota A;c Clostridia;c) Clostridiales;f Clostridiaceae;g Clostridium_S:cubacterium limosum
Sacteria;p, Bacillota A;c Clostridia;c) Lahonspirales;f Lachonspiraceae;g Enteroclosters. Enteroclosters sp801120905
Sacteria;p, Bacillota A;c Clostridia;c) Lahonspirales;f Lachonspiraceae;g Enteroclosters. Enteroclosters sp80120905
Sacteria;p, Bacillota;c, Bacilli;o, Bacillales;f Sacillaceae;g, Bacillus;s, Bacillus A;c Sacilla;c) Sacillais;f Sacillaceae;g, Bacillus;s, Bacillus A;c Sacilla;c) Sacillais;f Sacillaceae;g, Bacillus;a,c) Sacilla; A cerus
Sacteria;p, Bacillota;c, Bacilli;o, Bacillales;f Sacillaceae;g, Bacillus;a,c) Preista; Bacillaceae; Sacilla;c) Sacillais;g, Preista;g, Sacillais;g, Bacillais;g, Bacillais;g,
```

tax.bac120.summary.tsv,其记载了每个 MAG 所属的 species:

```
acillota;c__Gammapro
acillota;c__Bacilli;o__La
seudomonadota;c__Gammapro
acillota;c__Bacilli;o__La
```

使用方法:

python roary_split.py -help

- -i: 输入文件 1, species.txt 文件
- --tax: 输入文件 2, tax.bac120.summary.tsv 文件
- -t: genome 数量的阈值,只有超过该数值的 genome 才会被创建文件夹,默认: 10
- --thread: roary 程序调用的线程数
- --donotalign: 是否使用 MAFFT 对基因比对(roary 内置参数)

- -p: Prokka 文件夹。注意必须为绝对路径,不能使用相对路径
- -o: 输出文件,输出每个种及其对应的 species 数目用于后期作图。

```
$python roary_split.py --help
usage: roary_split.py [-h] -i <file> --tax <file> -t <file> --thread <file>
                      --donotalign <file> -p <file> -o <file> [--version]
Roary results
optional arguments:
 -h, --help
                        show this help message and exit
 -i <file>, --input <file>
                        Species file: species.txt.
  --tax <file>
                        Tax file: tax.bac120.summary.tsv.
 -t <file>, --threshold <file>
                        Number of genome, Default: 10.
  --thread <file>
                        Number of threads, Default: 10.
  --donotalign <file>
                        Do-not-align genes, Default: T.
  -p <file>, --prokka <file>
                        Prokka directory [ABS]. this directory is usde to link
                        gff file into sub-directory and process roary.
  -o <file>, --out <file>
                        Output file.
                        Display version
 --version
```